

基于多轴格拉姆角场与双分支 YOLOv8-cls 融合的轴承故障诊断方法

罗叶子¹ 高贵兵² 陈湘浩³

(湖南科技大学机电工程学院 湘潭 411201)

摘要: 针对多轴耦合调制、强噪声干扰下轴承故障诊断存在的耦合特征挖掘不充分、滑动窗口随机切分引发跨样本数据泄露等问题,提出了一种将多轴格拉姆角场(GAF)编码和 YOLOv8-cls 双分支卷积神经网络融合的故障诊断方法。该方法将三轴原始数据归一化后映射至极坐标空间,同步生成格拉姆角和场(GASF)与差场(GADF)两类特征图谱;再将 X/Y/Z 三轴分量分别映射至 RGB 三通道完成融合图像,完整保留多轴信号的相位特征和能量分布特征,避免单通道信息丢失;随后,构建双分支 YOLOv8-cls 网络,提取两类图像深层故障特征,并在概率输出层采用等权均值策略实现多图谱诊断信息互补。针对跨样本数据泄露问题,采用稳态场景时序隔离划分、变工况场景整文件迁移划分双重划分策略,阻断训练/测试集同源时序交叉污染。所有准确率均附带基于二项分布的 95%置信区间,确保评估结果的统计严谨性和可复现性。HUST 数据实验表明,所提方法准确率达到 99.76% [99.11, 99.93],与多轴 STFT 基线持平,且对滚动体等难分类别的诊断更稳定;CWRU 数据集补充实验准确率 99.41% [98.49, 99.77],验证了良好的跨数据集泛化能力。该方法兼具高精度诊断与无偏评估优势,可为多通道振动驱动的旋转装备智能诊断提供新范式。

关键词: 轴承故障诊断; 多轴振动信号; 格拉姆角场; YOLOv8-cls; 时频图像

中图分类号: TH133.3; TP183

文献标识码: A

Bearing Fault Diagnosis Method Based on Multi-Axis Gram Angle Field and YOLOv8-cls Dual-Branch Fusion

Luo Yezi¹ Gao Guibing² Cheng Xianghao³

(College of Mechanical and Electrical Engineering, Hunan University of Science and Technology, Xiangtan 411201)

Abstract: To address insufficient coupling feature mining and data leakage from random sliding - window segmentation in bearing fault diagnosis under multi - axis coupling and strong noise, we propose a method integrating multi - axis Gramian Angular Field (GAF) encoding with a dual - branch YOLOv8 - cls network. Triaxial signals are normalized, mapped to polar coordinates, and simultaneously transformed into GASF and GADF images, which are then fused into RGB channels to preserve phase and energy features. The dual - branch network extracts deep features, and equal - weight averaging enables complementary diagnosis. Strict data partitioning prevents temporal cross - contamination. All accuracies are reported with 95% binomial confidence intervals. Experiments on the HUST dataset achieve 99.76% [99.11, 99.93], comparable to multi - axis STFT and more stable for rolling elements; CWRU yields 99.41% [98.49, 99.77], confirming cross - dataset generalization. The method provides high - precision diagnosis and unbiased evaluation for multi - channel vibration - driven intelligent diagnostics.

Key words: Bearing fault diagnosis; multi-axis vibration signals; Gram angle field; YOLOv8-cl; time-frequency images

高速轨道交通、大型旋转机械等高端装备正朝着高速化、高可靠性方向纵深发展,轴箱轴承作为传动系统的核心部件,长期服役于高转速、强变载、高噪声耦合的复杂工况,其健康状态直接决定装备运行安全与全寿命周期运维成本。传统事后检修模式已难以满足设备的安全性、经济性要求,状态监测与预测性维护技术正成为保障装备可靠运行的主流范式。在此背景下,轴承等易损部件的精准健康评估,也成为提升系统可靠性、降低运维成本的关键技术。

工程实践表明,传统的故障诊断方法多依靠单通道振动信号,通过人工设计的特征指标或短时傅

里叶变换、小波变换等时频分析方法实现浅层分类。然而,面对多轴耦合调制、强噪声干扰与非平稳特征相互交织的复杂工况,此类方法普遍存在特征表征能力不足、跨工况泛化性弱、抗干扰性能受限等缺陷,难以满足装备高精度、高鲁棒性的诊断需求。

近年来,格拉姆角场(Gramian Angular Field, GAF)时序可视化方法可有效保留时序信号内在相关性与相位细节,已广泛应用于轴承故障诊断,为深度学习挖掘故障特征提供了全新表征思路。王劭鹤等^[1]将 GAF 用于 GIS 设备振动信号状态辨识,梁文举等^[2]结合格拉姆角差场与 MobileViT 实现电网主导失稳模式的智能辨识,证实了融合 GAF 图像

表征与先进识别机制在挖掘复杂动态信号深层特征方面的有效性与独特优势。但现有基于 GAF 的故障诊断研究仍存在多轴振动信息表征不充分的局限：多数研究仅针对单轴或双通道时序构建 GAF 图谱，缺乏对轴承三轴加速度耦合关联特征的挖掘。冯志刚等^[3]采用多通道 STFT 时频图加权融合实现齿轮箱诊断，但未涉及 GAF 多轴编码；占可等^[4]、古莹奎等^[5]、骆家杭等^[6]、姚立等^[7]均基于单轴时序生成 GAF 图像开展轴承诊断；贺才郡^[8]、王裕祥等^[9]虽尝试双通道 GAF 建模，但仅在深层特征维度实施简单拼接，未能在模型输入端利用 RGB 色彩通道同步封装三轴振动幅值与相位耦合信息，致使网络无法直接提取多轴联合故障判别特征。刘素艳等^[10]融合 GAF 与图神经网络实现变转速工况诊断，多轴信息仍依赖后端特征融合策略，未能从输入表征层面实现三轴信号统一编码，多轴耦合特征丢失问题未能解决。

得到充分承载多轴相位与能量耦合信息的特征图谱后，选取适配的高效鲁棒分类模型至关重要。现有基于 GAF 的轴承诊断研究普遍采用通用 CNN 或叠加复杂网络模块：李宗源等^[11]构建基于格拉姆角场的并行 CNN，庞新宇等^[12]构建 GAF-CNN 模型实现了行星齿轮箱的精准故障诊断，古莹奎等^[5]采用迁移深度残差网络，姚立等^[7]搭建 CNN-RNN。此类模块堆砌方法易造成参数冗余、性能增益逐步衰减，且主干网络未针对 GAF 图像纹理与结构优化，无法适配 GAF 专属特征分布。相比之下，YOLOv8-cls 作为 YOLO 系列中专攻图像分类的变体，其 C2f 模块与特征融合结构设计能够高效捕捉图像多层次特征，在训练稳定性、推理速度及多尺度输入适应性上具备综合优势，已被用于交通标志检测^[13]、道路损伤检测^[14]、航拍图像检测^[15]等工业场景，邱天衡等^[16]将 YOLOv5 与 GAF 结合用于磁性目标识别，但将 YOLOv8-cls 与多轴 GAF 融合用于轴承故障诊断的研究尚未见报道。

除模型架构层面的创新外，轴承诊断的评估策略同样影响结论的可信度。夏之罡等^[17]、强睿儒等^[18]、在 GAF 轴承诊断研究中多采用随机划分训练/测试集的方法，未规避滑窗重叠导致的信息耦合，评估结果存在虚高隐患；同时，现有研究未针对稳态、变工况两类典型场景设计差异化的数据划分协议，变工况场景下若同文件切分训练与测试集，极易拟合该文件固有的工况变化规律，无法真正检验跨文件泛化与迁移能力。张兴武等^[19]在高铁转向架轴承诊断中明确指出评估协议工程适配性的重要性，但在 GAF 轴承诊断领域仍未形成严格的时序划分

共识与统一评估基准。

综上，尽管基于 GAF 与深度学习的故障诊断研究已取得显著进展，但在面向复杂工业实际应用时仍存在三方面核心挑战：

(1) 多轴信息融合策略停留在后期特征拼接，未能在输入层将三轴信号的幅值—相位耦合关系编码为统一的 RGB 图像表征；

(2) 评估协议缺乏科学性与适配性，随机划分难以避免滑窗重叠导致的信息耦合，结论工程可信度存疑；

(3) 模型设计与 GAF 图像适配性不足，盲目堆叠注意力或时序模块边际效益递减，忽视了针对 GAF 特有纹理结构的轻量化 backbone 适配优化。

针对上述挑战，本文提出多轴 GAF-RGB 双分支 YOLOv8-cls 轴承故障诊断方法。该方法首先通过三轴 GAF-RGB 编码策略在输入层实现多轴幅值-相位耦合信息的统一表征；其次设计双主线差异化划分协议，分别针对稳态与变工况场景构建可信评估基准；最后基于 YOLOv8-cls 构建双分支特征提取网络，实现 GASF 幅值特征与 GADF 相位特征的互补融合。在 HUST 稳态数据集、MCC5 变工况数据集、CWRU 公开数据集上的实验结果表明，所提方法在诊断精度与泛化能力上均具有较大优势。

1 多轴 GAF-RGB 双分支故障诊断框架

1.1 三轴振动 GAF-RGB 联合表征机制

传统傅里叶与小波变换均依赖信号平稳性前提，难以兼顾时序全局演化规律与局部冲击细节。GAF 无需选取窗函数、基函数，依托归一化信号的幅值与相位构建全局关联图谱，可同步保留时序整体变化趋势与局部瞬态特征。该方法借助极坐标映射和三角内积运算生成格拉姆矩阵，实现一维时序向二维图像的转换，其中 GASF、GADF 分别基于和角与差角运算表征信号的自相似规律与瞬时突变特性，能完整刻画信号的周期分量与故障冲击信息。

设原始时序数据为 $X=\{x_1, x_2, \dots, x_i\}$ ，首先用式(1)将数据归一化至 $[-1, 1]$ 区间：

$$\bar{x}_i = \frac{2x_i - \max X - \min X}{\max X - \min X} \quad (1)$$

式中， $\bar{x}_i$ 归一化后的第 i 个采样点的值， $\max X$ 、 $\min X$ 为序列的最大、最小值。随后将归一化后的数据映射到极坐标系，转换规则如式(2)所示：

$$r_i = \bar{x}_i, \theta_i = \arccos(\bar{x}_i) \quad (2)$$

式中， $i, j = 1, 2, \dots, T$ ， T 为采样数， r_i 和 θ_i 分别对应第 i 个采样点的极径和极角。完成时序极坐标映射后，GAF 通过两种引入抑制项的三角内积构造格拉姆矩阵，以削弱信号中高斯噪声带来的干

扰，两类矩阵的元素定义如下：

$$\langle x_i, x_j \rangle = \cos(\phi_i + \phi_j) \quad (3)$$

$$\langle x_i, x_j \rangle = \sin(\phi_i - \phi_j) \quad (4)$$

式(3)、(4)分别为 GASF 和 GADF 格拉姆矩阵的构造公式， $\langle x_i, x_j \rangle$ 为格拉姆矩阵的第 (i, j) 个元素， ϕ_i 和 ϕ_j 分别为第 i 个采样点对应的极角。其中 GASF

通过和角余弦关系表征时序幅值关联，侧重刻画信号全局能量相似特征；GADF 依托相位差正弦运算，对冲击、调制等局部非平稳故障分量具备更高敏感性，两者结合可在二维图像中同时保留时序全局演化规律与局部瞬态突变细节。具体信号转换流程如图 1 所示。




图 1. 三轴振动信号联合编码生成多轴 GAF-RGB 图像示意图

Fig.1 Schematic diagram of RGB image generation from triaxial vibration signals via joint encoding into Gramian Angular Fields




图 2 多通道堆叠示意图

Fig.2 Schematic diagram of multi-channel stacking




图 3 不同故障类别下的 GASF 与 GADF 图像示例

Fig.3 Examples of GASF and GADF images for different fault categories

本研究针对多轴振动信号特性，将 GAF 拓展为多轴 GAF-RGB 格式：对 X、Y、Z 三轴信号分别构建 GASF 与 GADF 矩阵，并依 X→R、Y→G、Z→B 顺序在通道维度堆叠，使单幅图像同时包含三轴的幅值能量与相位差信息，如图 2 所示。

图 3 展示了不同故障类别下 GASF 与 GADF 图像的视觉特征差异。健康状态下图像纹理规则，故障状态下呈现紊乱分布。GASF 图像色调均匀、纹理平滑，侧重能量分布与全局周期性；GADF 图像包含明显斜向条纹与局部突变，对相位差和瞬态冲击更敏感。两者互补的表征为双分支网络提供了物理含义清晰的先验信息。

1.2 轻量化双分支 YOLOv8-cla 特征融合分类网络

本研究选取 YOLOv8-cla 作为 GAF-RGB 图像分类的骨干网络。该模型通过 C2f 模块与 FPN-PAN 特征融合结构，能有效融合多尺度特征，精准捕捉 GAF 图像的全局纹理结构与局部瞬态冲击特征；其分类头采用全局平均池化替代全连接层，在降低参数量与过拟合风险的同时，兼顾了推理效率与训练稳定性。

选取该架构主要基于两方面考量：第一，该架

构可以直接处理三通道 GAF-RGB 彩色图像，能有效提取图像中的空间关联特征；第二，统一的骨干架构便于不同的图像表征之间的公平对比，确保模型的性能差异源于表征本身，而非网络结构差异。

1.3 故障诊断流程设计与实现

针对多轴轴承振动信号的故障诊断需求，本文

构建了多轴 GAF-RGB 与双分支 YOLOv8-cla 融合的故障诊断方法。方法的整体技术路线如图 4 所示，主要包括三个阶段：包括多轴振动信号预处理与切片、多轴 GAF-RGB 图像生成、双分支 YOLOv8-cla 训练与推理。




图 4 多轴 GAF-RGB 与双分支 YOLOv8-cla 融合的轴承故障诊断技术路线图

Fig.4 Flowchart of a Multi-Axis GAF-RGB Dual-Branch YOLOv8-cla Fault Diagnosis Method

第一阶段为信号预处理与切片，对原始三轴振动信号进行去均值、标准差归一化及全局百分位鲁

棒缩放，以消除量纲差异并抑制异常脉冲干扰；在每个原始文件内按固定窗长与步长进行滑动窗口切

片，得到带标签的多轴振动片段，为 GAF 转换提供基础。

第二阶段为多轴 GAF-RGB 图像生成：对每一轴的振动片段独立计算 GASF 与 GADF 矩阵，再按 $X \rightarrow R$ 、 $Y \rightarrow G$ 、 $Z \rightarrow B$ 的映射关系在通道堆叠，生成 GASF-RGB 与 GADF-RGB 两类三通道图像，在图像空间中同时保留多轴能量分布与相位耦合关系。在图像输入层实现多轴信号能量分布与相位耦合关系的统一表征。

第三阶段为双分支网络训练与推理：在网络结构上，GASF-RGB 与 GADF-RGB 图像分别输入两个结构相同、参数独立的 YOLOv8-cls 分支，经 Softmax 层得到后验概率向量 p_{gasf} 和 p_{gadf} ，在概率层采用等权均值策略进行融合：

$$p = \frac{(p_{\text{gasf}} + p_{\text{gadf}})}{2} \quad (5)$$

取 p 中最大概率对应的故障类别为最终诊断结果。双分支结构能够充分利用 GASF 与 GADF 在幅值相关性与相位差表征上的互补信息，而等权均值融合策略不引入额外可学习参数，具有结构简洁、计算高效、易于实现的优势。作为改进方案，本文还尝试在输出层前增加轻量级 MLP 分支注意力模块，通过学习得到的自适应权重对两路概率进行加权融合，以评估自适应加权策略在当前诊断任务中的边际增益。

上述双分支融合机制将多轴 GAF-RGB 图像映射为高维特征空间中的判别性特征表示，并据此输出故障类别概率。这些表示虽然不对应明确的物理参量，但本质上是对原始多轴振动信号的能量分布、全局相位相关性、瞬态冲击特性及耦合关系等物理信息的深层抽象编码。网络通过训练优化使这些特征最大程度地区分健康状态与不同故障类型，从而实现端到端的智能故障诊断。

2 双主线差异化可信评估协议设计

2.1 稳态场景时序隔离划分机制

滑动窗口切片带来的数据泄露问题，其本质源于时间序列的强自相关性。具体表现为：在固定转速与载荷的稳态实验中，故障特征具有显著的时序依赖性，即使增大滑动步长消除片段间的物理重叠，相邻样本在时域上仍紧密相连且分布高度一致。设原始振动信号为 $x(t)$ ，滑动窗口以步长 Δt 切片，得相邻片段 $S_i = x[t_i, t_i + T]$ 和 $S_{i+1} = x[t_{i+1}, t_{i+1} + T]$ 。当 $\Delta t < T$ 时， S_i 与 S_{i+1} 存在长度为 $T - \Delta t$ 的重叠区间，二者在时域上高度相关。若将 S_i 与 S_{i+1} 随机分配到训练集和测试集，则测试样本的信息已部分包含于训练样本中，导致评估结果虚高。

针对上述时序分布特性，本文提出稳态时序隔离划分策略，严格遵循时间先后顺序进行数据集构建，确立了以历史观测推断未来状态的验证范式，从而真实反映模型在实际工程中的时序外推能力。




图 5 稳态时序隔离划分示意图

Fig.5 Schematic diagram of steady-state temporal isolation partitioning

如图 5 所示为策略划分示意图，该策略的核心逻辑在于严格按时间顺序对文件内部片段进行物理

隔离，主要包含两个关键环节：

(1) 时序隔离：严格按照其在时间轴上的先后

顺序，对每一个原始文件内的所有滑窗片段按一定比例划分为训练集、验证集和测试集。

(2) 冗余控制：引入索引下采样机制，按固定间隔规则保留部分片段，同时设定类别上限，平衡样本权重。

时序隔离彻底切断了测试样本与训练样本在时间维度上的直接关联，消除了因时序自相关性导致的信息泄露风险，从而确保评估结果真实反映模型基于历史观测推断未来状态的时序外推能力；而冗余控制则有效降低了因滑窗步长较小产生的高度相似样本对训练的干扰，并通过类别上限平衡了不同故障类型的样本权重，进一步提升了模型对可迁移故障物理特征的学习效果，避免其过度拟合局部波形细节。二者协同在构建严谨评估基准的同时，提升了模型对可迁移故障特征的学习效果。

2.2 变工况场景整文件迁移划分机制

在变工况实验中，转速、载荷等运行条件连续变化，故障特征与工况参数高度耦合。此时若仍沿用文件内按时间切分的策略，训练集与测试集可能来自同一实验文件的不同时间段，模型仅检验同一轨迹的后续片段，无法评估对新工况的泛化能力。因此，本文将变工况场景的数据划分粒度由样本片段级提升至文件级。在每个故障类别内，按文件编号排序后，将整文件按一定比例分别划入训练集、验证集和测试集，不再在文件内部进行切分。由此保证测试集与训练集文件完全不相交，从而实现对跨文件、跨工况泛化能力的有效评估。

变工况下各文件产生的片段数量差异较大，若不加以约束，易造成各集合样本失衡。因此在 GAF 图像生成阶段采用分集合类别均衡策略，为每类故障在各集合中设定统一的样本数量上限，既保证各

类故障在各集合中均衡覆盖，又使数据集规模可控、便于复现实验。

从评估逻辑上看，两种场景形成互补：稳态场景关注同一采集条件下、不同时间片段的时序外推能力；变工况场景关注不同实验文件、不同工况组合之间的跨域迁移能力。

3 稳态工况性能评估

3.1 实验环境与数据集

HUST 数据集由华中科技大学多工况轴承实验平台采集，实验平台如图 6 所示，本文选取 30Hz 转速下的三轴振动信号，归并为健康、滚动体故障、内圈故障和外圈故障四类。该实验在恒定转速与载荷条件下采集长时间连续振动信号，三轴加速度传感器同步采集，采样频率 25.6kHz。



图 6 HUST 轴承实验平台及测点示意图

Fig.6 Schematic diagram of the HUST bearing test rig and measurement points

数据集的所有训练实验均基于 Ultralytics YOLOv8-cls 实现，训练时采用交叉熵损失函数和 Adam 优化器，初始学习率采用默认设置，总训练轮数为 40，批量大小为 32，不采用额外的早停或学习率重启策略，以便更直观地观察不同输入与结构的收敛趋势，具体样本划分设置如表 1 所示。

表 1 HUST 实验数据集滑动窗口生成与划分设置

Tab.1 Sliding Window Generation and Partition Settings for the HUST Experimental Dataset

故障类型	标签	训练样本数	验证样本数	测试样本数
健康	H	1050	225	225
滚动体故障	B	1050	225	225
内圈故障	I	1050	225	225
外圈故障	O	1050	225	225

注：表中测试集 900 为滑动窗口生成总量的理论封顶值。在稳态时序隔离划分主线中，为避免相邻片段间的时间耦合，引入索引下采样机制，实际测试集有效样本为 819（各类别为 205、205、205、204，由于索引下采样取整，外圈故障类测试样本为 204）；在稳态随机对照划分中，保留完整 900 个测试样本。后续表 2、表 3 中分别以 N=819 和 N=900 加以区分。

为评估诊断性能的统计可靠性，本文所有准确率均附带基于 Wilson Score Interval 计算的 95%置信区间，采用对应临界值 $z=1.96$ 。该方法直接对二项

分布比例进行区间估计，相较于传统正态近似，在高准确率或低准确率等极端比例情况下具有更准确的覆盖概率，能可靠反映诊断结果的统计波动范围。

3.1.1 消融实验与结果分析

为了验证所提方法的有效性并分析各模块的作用，在 HUST 数据集上设计了结构消融实验。实验在稳态时序隔离划分下进行，采用与表 1 一致的数据规模及相同训练配置，对比了四种模型结构：单分支 GASF-RGB、单分支 GADF-RGB、双分支等权均值以及双分支注意力融合。




表 2 四种模型结构在 HUST 上的诊断性能对比

Tab.2 Comparison of Diagnostic Performance of Four Model Architectures on HUST

诊断方法	验证集最高准确率 (%)	测试集总体准确率 (%)	宏平均 F1 (%)
GASF-RGB	99.12	99.27 [98.41, 99.66]	99.27
GADF-RGB	99.89	98.78 [97.77, 99.34]	98.78
双分支等权均值	100	99.76 [99.11, 99.93]	99.76
双分支注意力融合	100	99.63 [98.93, 99.88]	99.63

注：注意力融合在 Ball 类召回率约 99.51%，整体性能略低于等权均值。双分支验证集准确率为两分支概率在 val 上融合计算，非训练曲线峰值。表中方括号内为基于二项分布的 95%置信区间的下限和上限，HUST 稳态时序隔离划分下的测试集样本数 $N=819$ 。

对表 2 数据分析如下：

(1) 单分支性能互补性：GADF-RGB 验证集领先但测试集回落，GASF-RGB 验证集略低但测试集更稳，表明两分支对时间段的敏感方向不同，体现了多视图融合在特征互补上的价值，同时印证了稳态时序隔离划分的有效性：严格的时序隔离暴露单分支的泛化波动，避免验证假象误导选型。

(2) 双分支融合增益：双分支等权均值在测试集上取得最高准确率，且宏平均 F1 与准确率一致，说明提升来自各类别均衡改善，体现了 GASF 与 GADF 在能量相关与相位差特征上的互补纠错能力。

(3) 注意力融合与等权均值的对比：注意力融

图 7 不同模型在 HUST 上的损失与准确率迭代曲线

Fig.7 Training Loss and Validation Accuracy Curves of Different Models on the HUST Dataset

如图 7 所示，不同模型在 HUST 数据集上的损失与准确率迭代曲线直观反映了训练动态。得益于底层单分支特征提取器的预训练权重，双分支注意力融合仅通过微调约 10 个 epoch 的融合模块便迅速达到高准确率。这种参数冻结策略不仅显著降低了计算开销，也确保了融合阶段的高效收敛。

从收敛性来看，所有模型的训练损失均在 40 轮内快速下降并趋近于零，表明模型对训练数据拟合充分。在泛化性能方面，双分支等权均值与双分支注意力融合的验证准确率始终处于领先地位，且后期无明显波动，体现了多视图融合的鲁棒性；相比之下，GASF-RGB 与 GADF-RGB 单分支模型的验证准确率略低，且 GADF-RGB 前期波动更为明显，暴露出单分支特征表征的局限性。

在 HUST 稳态时序隔离划分测试集上，对单分支 GASF-RGB、单分支 GADF-RGB、双分支等权均值、双分支注意力融合四种模型结构进行消融对比，结果见表 2。

合测试集准确率（99.63% [98.93, 99.88]）低于等权均值（99.76% [99.11, 99.93]），但两者的 95%置信区间存在显著重叠，表明该差值在统计学上不显著。因此，注意力融合并未带来更稳健的泛化性能，而等权均值的优势主要体现在零额外参数量与更高的训练效率上。

综上，在单工况状态下，采用稳态时序隔离划分策略有效，且双分支等权均值在不增加模型复杂度的前提下取得与复杂融合相当的精度，是更优的工程化选择。

为进一步分析不同模型在收敛阶段的性能分布与稳定性差异，基于 HUST 数据集稳态时序隔离划

分下的验证过程，绘制了四种模型结构收敛段验证准确率、损失与召回率箱线图，结果如图 8 所示。

子图(a)、(b)显示，四种结构均在第 10 轮后稳定收敛，说明模型与数据匹配，实验具有可复现的训练基础。其中，GADF-RGB 验证准确率中位较高但存在下拖尾，GASF-RGB 整体略低但波动形态不同，表明两分支对验证片段的敏感方向存在差异。双分支简单平均的验证准确率与损失居于两者之间，未出现极端离群，体现融合后的折中与稳定。




图 8 四种模型结构在收敛段上的验证准确率、验证损失与滚动体类别召回率对比

Fig.8 Comparison of validation accuracy, loss, and recall for four models at convergence stage.

子图(c)聚焦滚动体类别：单分支召回分布偏低且离散较大，双分支简单平均箱体整体上移，说明融合对弱类具有系统性增益。注意力融合在验证指标上分布更集中，但该优势未完全传递至测试集。

综上，单分支的泛化波动验证了稳态时序隔离划分的合理性，双分支等权均值在测试集上取得最优性能，融合对弱类具有系统性增益。该方式在单工况下获得了稳定、可解释且结构简洁的诊断性能。

3.1.2 不同数据划分方式对比

为检验时序划分是否低估性能，或随机划分是否因数据泄漏高估结果，本节在相同设置下增设稳态随机对照基线：保持类内标签一致，仅解除时序连续性约束，评估模型在数据分布一致且无时间关联下的理论性能上限。

表 3 HUST 不同划分方式测试集准确率对比

Tab.3 Comparison of Test Set Accuracy Under Different Data Partitioning Strategies on HUST

划分方式	GASF(%)	GADF(%)	双分支等权均值(%)
稳态时序隔离划分	99.27 [98.41, 99.66]	98.78 [97.77, 99.34]	99.76 [99.11, 99.93]
稳态随机对照划分	99.44 [98.71, 99.76]	99.67 [99.02, 99.89]	99.89 [99.37, 99.98]

注：表中方括号内为基于二项分布的 95%置信区间的下限和上限，稳态时序隔离划分测试集样本数 $N_1=819$ ，稳态随机对照划分测试集样本数 $N_2=900$ 。

两种划分下测试集诊断性能对比如表 3 所示。从结果看，稳态时序隔离划分与稳态随机对照划分的性能差异在 1 个百分点以内。这说明：

(1) 稳态时序隔离划分结论并未因过严的时间隔离而人为压低性能评估；

(2) 稳态随机对照划分也未因数据泄漏而导致明显的性能虚高；

(3) 稳态时序隔离划分(99.76% [99.11, 99.93])与随机对照划分(99.89% [99.37, 99.98])高度重叠，进一步证实前者并未因严格的时间隔离而显著压低

性能，其评估结果具有统计可靠性。

在性能趋近饱和的任务中，划分方式对最终数值的影响处于较低量级，但稳态时序隔离划分更契合时序外推评估范式并有效抑制数据泄漏，因此在稳定工况下仍采用时序隔离划分作为主要评估协议。

3.2 变工况鲁棒性验证

3.2.1 实验设置与数据集

变工况鲁棒性验证采用 MCC5-THU 电机轴承数据集。该数据集涵盖转速循环与扭矩循环两类典型工况变化，旨在模拟实际工业环境中负载与转速

的动态波动。本文从中选取 48 组纯轴承振动数据，将健康、滚珠、内圈、外圈四种轴承状态在实验中分别标注为类 0、类 1、类 2、类 3。为消除传感器方向差异影响，三轴振动数据采用与 HUST 数据集一致的滑窗切分、归一化及 GAF-RGB 成像流程，确保特征提取可比性与实验结果公平性。

表 4 MCC5 变工况数据集三种划分方式样本规模

Tab.4 Sample Sizes of Three Partitioning Schemes for the MCC5 Dataset under Variable Operating Conditions

• 划分方式	训练集 总数	验证集 总数	测试集 总数	各类测试 样本数
整文件迁移 划分	4200	900	900	225
变工况时序 隔离划分	—	—	508	127
变工况随机 对照划分	4200	900	900	225

MCC5 变工况数据集划分设置如表 4 所示。变

表 5 变工况整文件迁移划分下两分支四类故障预测准确率

Tab.5 Prediction Accuracy of the Dual-branch Model for Four Fault Categories

方法	总体(%)	类 0(%)	类 1(%)	类 2(%)	类 3(%)
GASF-RGB	97.33	94.22	97.78	99.56	97.78
	[96.06, 98.20]	[90.37, 96.59]	[94.90, 99.05]	[97.53, 99.92]	[94.90, 99.05]
GADF-RGB	94.11	99.56	92.89	85.78	98.22
	[92.38, 95.47]	[97.53, 99.92]	[88.76, 95.58]	[80.61, 89.74]	[95.52, 99.31]
双分支等权均 值	99.33	99.56	98.67	99.56	99.56
	[98.55, 99.69]	[97.53, 99.92]	[96.15, 99.55]	[97.53, 99.92]	[97.53, 99.92]

注：表中方括号内为基于二项分布的 95%置信区间的下限和上限，表中均为整文件迁移划分，该划分下测试集样本总数 $N=900$ ，各故障类别测试集样本数 $n=225$ 。

与稳态结果相比，变工况下单分支准确率有所下降且类间差异扩大，符合跨文件泛化难度更高的预期规律。融合后准确率仍保持在 99%以上，表明所提多轴 GAF-RGB 双分支框架在工况连续变化场景下仍具有较强的诊断精度。

表 6 MCC5 数据集下不同划分方式下测试集性能对比

Tab.6 Comparison of Test Set Performance Under Different Data Partitioning Strategies on MCC5

划分方式	GASF(%)		GADF(%)		双分支等权均值(%)		测试集样本数量(%)
整文件迁移划分	97.33	[96.06, 98.20]	94.11	[92.38, 95.47]	99.33	[98.55, 99.69]	900
变工况时序隔离划分	86.42	[83.16, 89.12]	82.68	[79.14, 85.72]	87.20	[84.02, 89.83]	508
变工况随机对照划分	97.78	[96.59, 98.56]	96.33	[94.90, 97.38]	98.67	[97.68, 99.24]	900

注：表中方括号内为基于二项分布的 95%置信区间的下限和上限。

整文件迁移划分与随机对照划分性能基本一致，表明随机划分未引入明显的数据泄漏偏差，主评估

工况主线采用变工况整文件迁移划分；训练配置与 HUST 数据集保持一致：Ultralytics YOLOv8n-cls、Adam、交叉熵损失、40 个训练轮次、batch size=32、输入图像尺寸 $\text{imgsz}=128$ 。模型在变工况整文件迁移划分得到的训练集上训练，测试集仅用于最终性能评估。

3.2.2 诊断结果分析

变工况整文件迁移划分下的诊断结果如表 5 所示。从单分支表现来看，GASF-RGB 与 GADF-RGB 在不同故障类别上呈现明显的性能互补特征。值得注意的是，GASF 的置信区间下限（96.06%）高于 GADF 的上限（95.47%），表明前者在变工况下的总体准确率具有统计显著性优势。具体类别上，GADF-RGB 在内圈故障上的分类准确率较低，而 GASF-RGB 在该类别上表现出较高的分类准确率。双分支等权均值融合后，各类别预测准确率均达到较高水平，整体误判样本极少，说明两分支在幅值相关与相位差表征上具有良好的互补性。

3.2.3 其他划分对比

除变工况整文件迁移划分主线外，本文另设两类划分方式作为对照，分别对应单工况验证实验中的时序隔离划分与随机划分方式，旨在检验评估协议对性能评估结论的影响，结果如表 6 所示。

协议的结论可信。时序隔离划分下性能出现显著回落，这是由于工况间的剧烈变化导致模型难以跨越

工况边界进行大幅外推预测。该结果印证了跨工况泛化的高难度挑战，也表明本文方法在严苛的整文件迁移评估下仍具备较强的鲁棒性。

4 跨数据集泛化性验证

CWRU (Case Western Reserve University) 轴承数据集是故障诊断领域广泛使用的经典数据集。为检验所提方法从实验室双主线向权威公开数据集迁

移的泛化能力，本文采用 CWRU v2 修正管线，对驱动端 12kHz 单通道振动信号进行 GAF-RGB 成像，并沿用双分支融合及时序隔离划分策略进行验证。实验涵盖了正常状态与三种典型故障类型，具体定义为：类 0 代表正常轴承，类 1、类 2 和类 3 分别对应内圈、外圈与滚动体故障。CWRU v2 时序隔离划分测试集上的实验结果如表 7 所示。

表 7 CWRU 测试集诊断准确率对比

Tab.7 Comparison of Diagnostic Accuracy on the CWRU Test Set

方法	总体(%)	类 0(%)	类 1(%)	类 2(%)	类 3(%)
GASF-RGB	99.11	99.47	99.39	99.38	98.15
	[98.07, 99.59]	[97.03, 99.91]	[96.65, 99.89]	[96.57, 99.89]	[94.70, 99.37]
GADF-RGB	98.37	100.00	98.79	100.00	94.44
	[97.11, 99.09]	[97.99, 100.00]	[95.69, 99.67]	[97.67, 100.00]	[89.78, 97.05]
双分支等权均值	99.41	100.00	100.00	99.38	98.15
	[98.49, 99.77]	[97.99, 100.00]	[97.72, 100.00]	[96.57, 99.89]	[94.70, 99.37]

注：表中方括号内为 95%置信区间，计算方法详见 3.1 节。测试集总样本数 $N=675$ ，各分类别样本数 n 依次为 187、165、161、162。

从表中可看出，双分支等权均值的总体准确率达 99.41%，略优于 GASF-RGB 单分支与 GADF-RGB 单分支。GASF 与 GADF 的分类准确率分别为 98.15%和 94.44%，揭示了单分支模型的类别特异性缺陷；而双分支融合成功弥补了这一短板，将最差类别的准确率提升至 98.15%。尽管双分支融合与 GASF 单分支的总体置信区间略有重叠（前者 [98.49, 99.77]，后者[98.07, 99.59]），但融合后薄弱类别（滚动体）召回率由单分支最低的 94.44%提升至 98.15%，置信区间显著右移，证明等权均值学习在提升模型整体稳健性方面的价值。




图 9 CWRU v2 双分支等权均值混淆矩阵

Fig.9 CWRU v2 two-branch simple averaging confusion matrix

双分支等权均值在 CWRU 测试集上的混淆矩阵如图 9 所示。模型在正常状态、内圈故障和外圈

故障上均实现了近乎完美的分类准确率，滚动体故障的召回率为 98.15%，仅存在极少量误判。整体混淆矩阵呈显著的对角优势，表明该方法在经典公开数据集上同样具备稳定的诊断精度。

与 HUST、MCC5 主线结果相比，所提方法在 CWRU 数据集上的测试准确率仍保持在 99%以上（99.41%），表明 GAF-RGB 双分支框架具备优异的跨数据集泛化能力。

5 结论

针对现有 GAF 轴承诊断方法在多轴信息表征、评估协议设计与模型架构适配等方面的不足，本文提出了一种多轴 GAF-RGB 双分支 YOLOv8-cls 轴承故障诊断方法，并在稳态、变工况数据集上进行了验证，主要结论如下：

（1）提出了多轴振动信号 GAF-RGB 源头耦合表征方法。该方法突破了传统单轴信号独立变换后拼接的特征提取范式，将 X、Y、Z 三轴振动信号分别编码为 GASF 与 GADF 矩阵，并按 RGB 三通道堆叠为单幅彩色图像，在数据输入层实现多维信息的物理耦合，完整保留了各轴间的能量分布差异与相位协同关系。在 HUST 稳态数据集上，基于该表征的双分支模型诊断准确率达 99.76% [99.11, 99.93]，验证了多轴耦合表征的有效性。

（2）验证了双分支等权均值融合的工程价值。在 HUST 测试集上，双分支等权均值准确率达 99.76% [99.11, 99.93]，与注意力融合策略 99.63% [98.93, 99.88]在统计学上无显著差异，但前者无需

额外可学习参数、训练成本更低，且在滚动体等薄弱类别上稳定性更优。这一结果表明，在 GAF 图像分类任务中，轻量化的等权平均融合比堆叠复杂注意力模块更具性价比。

(3) 建立了面向工业现场的双主线严格评估协议。针对现有研究中普遍存在的数据泄漏问题，制定了与工况特征相匹配的差异化划分标准。实验表明，在 MCC5 数据集上，若误用同文件时序划分，准确率将大幅降至 87.20% [84.02, 89.83]，而本文采用的整文件迁移划分达 99.33% [98.55, 99.69]，验证了划分协议与工况特征匹配的必要性。

(4) 实现了跨数据集的递进式验证。本文完成了从实验室稳态 HUST 数据集 (99.76% [99.11, 99.93])、变工况 MCC5 数据集 (99.33% [98.55, 99.69]) 到经典公开基准 CWRU 数据集 (99.41% [98.49, 99.77]) 的全链路验证。三个数据集涵盖稳态/变工况、三轴/单通道、实验室/公开基准等多种条件，所提方法均保持 99% 以上的诊断精度，证明了该方法不依赖特定实验台的数据分布特性，具备了向实际工业场景迁移的算法基础。

(5) 具备实际工业应用价值。首先，GAF-RGB 图像编码过程仅涉及极坐标变换与矩阵运算，计算复杂度低，可在嵌入式系统或边缘计算设备上实时完成信号到图像的转换。其次，YOLOv8-cls 作为轻量级分类网络，推理速度快，单张图像分类耗时在毫秒级别，满足在线监测的实时性要求。此外，该方法在 HUST、MCC5 和 CWRU 三个不同数据集上均保持 99% 以上的诊断精度，表明其对不同实验台、不同工况具有良好的泛化能力，降低了模型现场部署的重新训练成本。

参 考 文 献

- [1] 王劲鹤, 赵琳, 杨勇, 等. 基于振动信号格拉姆角场增强的 GIS 设备运行状态辨识方法[J]. 高压电器, 2025, 61(8): 39-46.
- [2] 梁文举, 胡婷婷, 范丽, 赵永龙, 冯智慧, 周昊, 南璐, 张鸿皓. 基于特征工程与图像识别的电网主导失稳模式智能辨识[J]. 电网技术, 1-12.
- [3] 冯志刚, 王楠. 强噪声与小样本下的齿轮箱多通道

- RGB 融合故障诊断方法[J]. 铁道科学与工程学报, 2026. (网络首发)
- [4] 占可, 王寅杰, 董路南, 等. 基于改进格拉姆角场和注意力机制的滚动轴承故障诊断[J]. 轴承, 2024(8): 80-85+94.
- [5] 古莹奎, 吴宽, 李成. 基于格拉姆角场和迁移深度残差神经网络的滚动轴承故障诊断[J]. 振动与冲击, 2022, 41(21): 228-237.
- [6] 骆家杭, 张旭, 汪靖翔. 基于格拉姆角场和多尺度 CNN 的轴承故障诊断[J]. 轴承, 2022(6): 73-78.
- [7] 姚立, 孙见君, 马晨波. 基于格拉姆角场和 CNN-RNN 的滚动轴承故障诊断方法[J]. 轴承, 2022(2): 61-67.
- [8] 贺才郡, 李开成, 杨王旺, 董宇飞, 宋朝霞, 范伟欣, 王伟. 基于双通道 GAF 和深度残差网络的电能质量复合扰动识别[J]. 电网技术, 2023, 47(1): 369-379.
- [9] 王裕祥, 高阳, 蒋恩超, 等. 基于 GAF-MACNN 的风机叶片健康状态监测方法[J]. 机械工程学报, 2026, 62(7): 139-149. DOI: 10.3901/JME.260369
- [10] 刘素艳, 王春辉, 孙学浩, 等. 多源特征节点的图神经网络轴承变转速故障诊断[J]. 振动与冲击, 2026, 45(3): 201-209+218.
- [11] 李宗源, 陈谦, 钱倍奇, 牛应灏, 张政伟. 基于格拉姆角场与并行 CNN 的并网逆变器开关管健康诊断[J]. 电力自动化设备, 2024, 44(8): 153-159.
- [12] 庞新宇, 仝钰, 魏子涵. 一种 GAF-CNN 行星齿轮箱故障诊断方法[J]. 北京理工大学学报, 2020, 40(11): 1161-1167.
- [13] 熊恩杰, 张荣芬, 刘宇红, 彭靖翔. 面向交通标志的 Ghost-YOLOv8 检测算法[J]. 计算机工程与应用, 2023, 59(20): 200-207.
- [14] 李松, 史涛, 井方科. 改进 YOLOv8 的道路损伤检测算法[J]. 计算机工程与应用, 2023, 59(23): 165-174.
- [15] 付锦臻, 张自嘉, 孙伟, 邹凯鑫. 改进 YOLOv8 的航拍图像小目标检测算法[J]. 计算机工程与应用, 2024, 60(6): 100-109.
- [16] 邱天衡, 王玲, 王鹏, 白燕娥. 基于改进 YOLOv5 的目标检测算法研究[J]. 计算机工程与应用, 2022, 58(13): 63-73.
- [17] 夏之罡, 楼小波, 马爱军, 等. 基于频域格拉姆角场与多尺度深度残差网络的高频变负载滚动轴承故障诊断研究[J]. 现代制造工程, 2025(1): 137-147+162.
- [18] 强睿儒, 赵小强. 基于格拉姆角差场和生成对抗网络的小样本滚动轴承故障诊断方法[J]. 华南理工大学学报(自然科学版), 2024, 52(10): 64-75.
- [19] 张兴武, 孙浩瑜, 李妍琦, 等. 多频谱融合评价方法及高铁转向架轴承故障诊断方法[J]. 机械工程学报, 2026, 62(2): 73-90. DOI: 10.3901/JME.260038

收稿日期: 2026-07-27

第一作者: 罗叶子 (2005-08), 女, 本科生, Email: luoyezi@mail.hnust.edu.cn

*通讯作者: 高贵兵 (1974.03), 男, 副教授, 博士, 主要从事制造系统建模、优化, 制造系统脆弱性分析、制造系统维护决策优化等研究, Email: gaoguibing@hnust.edu.cn